ANKARA ÜNİVERSİTESİ

MÜHENDİSLİK FAKÜLTESİ

BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

BLM 4522 PROJE RAPORU

Veri Temizleme ve ETL Süreçleri Tasarımı

Özge TARAŞLI

21290755

Github Adı: ozgetarasli

Github Proje Linki:

https://github.com/ozgetarasli/ag-tabanli-paralel-dagitim-sistemleri-projeleri/tree/main/Veri_Temizleme_ve_ETL_S%C3%BCre%C3%A7leri_Tasar%C4%B1m%C4%B1

Video Linki:

https://1drv.ms/v/c/c709e8ea336c06b2/IQBSosxJGZsPSJO9982o2KMRAXcc22xWt5vP-ogNijUNQjU?e=vWci9Y

ÖZET

Bu projede, Microsoft SQL Server ortamında Northwind veritabanı kullanılarak ETL (Extract, Transform, Load) süreçleri uygulanmıştır. Gerçek dünya veri kalitesi problemlerini simüle etmek amacıyla Customers ve Orders tabloları staging katmanına kopyalanmış, ardından kasıtlı olarak eksik veriler, tutarsız formatlar, gereksiz boşluklar, mükerrer kayıtlar ve mantıksız tarih değerleri oluşturulmuştur.

Staging tabloları üzerinde NULL değer yönetimi, duplicate kayıtların temizlenmesi, metin standartlaştırması (TRIM ve UPPER), mantıksız veri düzeltme, türetilmiş alan oluşturma (OrderYear) ve kategorizasyon (FreightCategory) gibi temizleme ve dönüştürme işlemleri gerçekleştirilmiştir. Temizlenen ve zenginleştirilen veriler, Clean_Orders adlı nihai tabloya yüklenerek analiz için hazır hale getirilmiştir.

Proje sonucunda, ham verilerden tutarlı, kaliteli ve analize uygun bir veri seti elde edilmiş olup, veri mühendisliğinde ETL süreçlerinin ve veri kalitesi yönetiminin önemi somut olarak gösterilmiştir.

İÇİNDEKİLER

ÖZET **2**
İÇİNDEKİLER 3
1. GİRİŞ 4
1.1 Kullanılan Ortam 4
1.2 Veritabanı Kurulumu 4
1.3 Amaç ve Planlama 4
2. EFTL SÜREÇLERİ VE UYGULAMA 5
2.1 Staging (Ara Katman) Oluşturma 5
2.2 Veri Bozulma ve Kalite Testleri 6
2.2.1 Null Değerler 6
2.2.2 Tutarsız Veri 7
2.2.3 Boşluk Sorunları 7
2.2.4 Mükerrer(Duplicate) Sorunları 7
2.3 Veri Temizleme Stratejileri(Transform) 8
2.3.1 Null Yöntemi 8
2.3.2 Mükerrer(Duplicate) Kontrolü 10
2.3.3 TRİM İşlemi(Boşluk) Temizleme 12
2.3.4 Veri Standartlaştırma 13
2.3.5 Mantıksız Veri Kontrolü 15
2.4 Veri Dönüştürme ve Zenginleştirme 17
2.4.1 Yeni Alan Oluşturma(OrderYear) 17
2.4.2 Veri Kategorizasyonu (FreightCategory) 19
2.4.3 Veri Zenginleştirme(JOIN) 19
2.5 Veri Yükleme(Load) 20
2.5.1 Nihai Tabloların Oluşturulması 20
2.5.2 Nihai Veri Kontrolü 22
2.6 Veri Kalitesi Kontrolü ve Raporlama 23
2.6.1 Eksik Veri ve Düzeltme İstatistikleri 23
2.6.2 Mükerrer Tablo Sonrası Kayıt Durumu 23
2.6.3 Ülke Dağılı ve Standartlaştırma Analizi 24
2.6.4 Kargo Ücretleri(Freight) Dağılımı Analizi 25
3. SONUÇ 26

1. GİRİŞ

Bu proje, modern veri ambarı mimarilerinde kritik bir rol oynayan **ETL (Extract, Transform, Load)** süreçlerinin tasarımını ve uygulanmasını konu almaktadır. Veri temizleme süreçleri; kirli veya tutarsız verilerin analiz öncesinde ayıklanarak veri kalitesinin artırılmasını hedefler.

1.1. Kullanılan Ortam

- Veritabanı Sistemi: Microsoft SQL Server 2022
- Yönetim Aracı: SQL Server Management Studio (SSMS)
- Örnek Veri Seti: Northwind Database

1.2. Veritabanı ve Senaryo

Projede Northwind örnek veritabanındaki Customers ve Orders tabloları temel alınmıştır. Gerçek hayattaki veri kalitesi sorunlarını yansıtmak için veriler önce staging tablolarına (Customers_Staging ve Orders_Staging) kopyalanmış, ardından çeşitli veri kalitesi problemleri bilinçli olarak eklenmiştir. Tüm temizleme ve dönüştürme işlemleri bu staging tabloları üzerinde gerçekleştirilerek orijinal verilerin bütünlüğü korunmuştur.

1.3. Amaç ve Planlama

Projenin temel amacı, ham veriyi alıp belirli kurallara göre temizleyerek tutarlı bir hale getirmektir:

- Extract (Çekme): Orijinal tabloların kopyalarının (Staging) oluşturulması.
- Transform (Dönüştürme): Hatalı verilerin (NULL değerler, mükerrer kayıtlar, gereksiz boşluklar) tespiti ve düzeltilmesi.
- Load (Yükleme): Temizlenen verinin hedef tabloya aktarılması.

2. ETL SÜREÇLERİ VE UYGULAMA

2.1. Staging (Ara Katman) Oluşturma

Orijinal verilere zarar vermemek ve çalışma alanını ayırmak için staging tabloları oluşturulmuştur. Customers ve Orders tabloları ara katmana taşınmıştır.

Staging Tablolarını oluşturan sorgu:

```
-- Staging müşteri tablosu oluşturma

SELECT * INTO Customers_Staging FROM Customers;


-- Staging sipariş tablosu oluşturma

SELECT * INTO Orders_Staging FROM Orders;
```

Staging tablolarının başarıyla oluşturulduğu iki farklı şekilde doğrulanabilir. İlk olarak, SQL Server Management Studio (SSMS) arayüzünde sol tarafta yer alan tablolar bölümünde Customers_Staging ve Orders_Staging tablolarının listelendiği görülmektedir. Bu durum aşağıdaki Şekil 1'de gösterilmiştir.

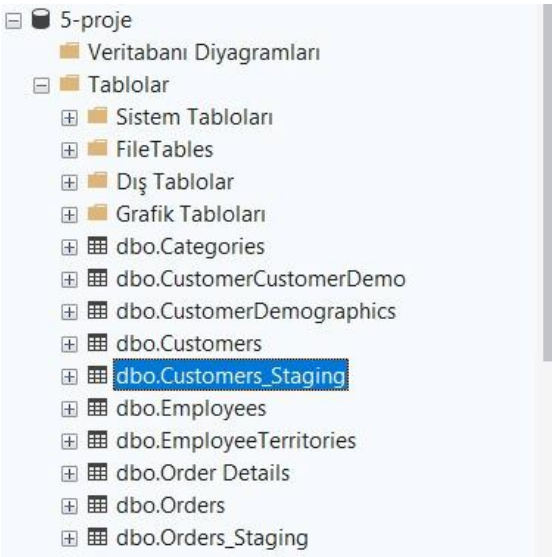

Şekil 1: SSMS Nesne Gezgini Üzerinde Oluşturulan Customers_Staging ve Orders_Staging Ara Katman Tablolarının Görünümü

İkinci olarak ise, ilgili tabloların içeriği SQL sorguları çalıştırılarak kontrol edilebilir. Aşağıdaki sorgular kullanılarak staging tablolarındaki veriler görüntülenmiş olup, sonuçlar Şekil 2'de sunulmuştur.

```
SELECT * FROM Customers_Staging;

SELECT * FROM Orders_Staging;
```

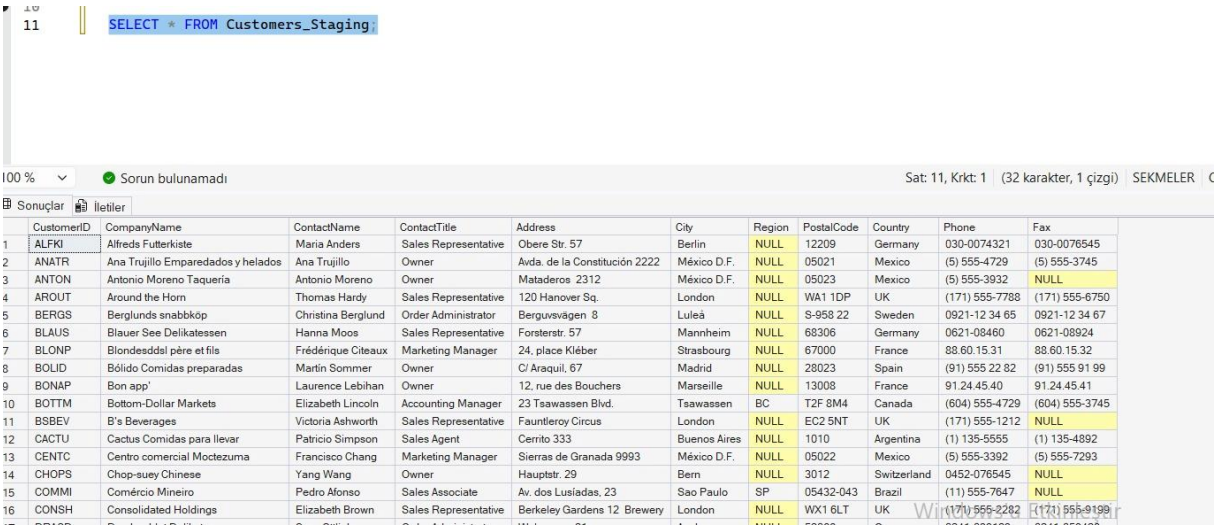

```
11  SELECT * FROM Customers_Staging;
```

100 % Sorun bulunamadı Sat: 11, Krkt: 1 (32 karakter, 1 çizgi) SEKMELER

Sonuçlar | Iletiler

	CustomerID	CompanyName	ContactName	ContactTitle	Address	City	Region	PostalCode	Country	Phone	Fax
1	ALFKI	Alfreds Futterkiste	Maria Anders	Sales Representative	Obere Str. 57	Berlin	NULL	12209	Germany	030-0074321	030-0076545
2	ANATR	Ana Trujillo Emparedados y helados	Ana Trujillo	Owner	Avda. de la Constitución 2222	México D.F.	NULL	05021	Mexico	(5) 555-4729	(5) 555-3745
3	ANTON	Antonio Moreno Taquería	Antonio Moreno	Owner	Mataderos 2312	México D.F.	NULL	05023	Mexico	(5) 555-3932	NULL
4	AROUT	Around the Horn	Thomas Hardy	Sales Representative	120 Hanover Sq.	London	NULL	WA1 1DP	UK	(171) 555-7788	(171) 555-6750
5	BERGS	Berglunds snabbköp	Christina Berglund	Order Administrator	Berguvsvägen 8	Luleå	NULL	S-958 22	Sweden	0921-12 34 65	0921-12 34 67
6	BLAUS	Blauer See Delikatessen	Hanna Moos	Sales Representative	Forsterstr. 57	Mannheim	NULL	68306	Germany	0621-08460	0621-08924
7	BLONP	Blondesddsl père et fils	Frédérique Citeaux	Marketing Manager	24, place Kléber	Strasbourg	NULL	67000	France	88.60.15.31	88.60.15.32
8	BOLID	Bólido Comidas preparadas	Martín Sommer	Owner	C/ Araquil, 67	Madrid	NULL	28023	Spain	(91) 555 22 82	(91) 555 91 99
9	BONAP	Bon app'	Laurence Lebihan	Owner	12, rue des Bouchers	Marseille	NULL	13008	France	91.24.45.40	91.24.45.41
10	BOTTM	Bottom-Dollar Markets	Elizabeth Lincoln	Accounting Manager	23 Tsawassen Blvd.	Tsawassen	BC	T2F 8M4	Canada	(604) 555-4729	(604) 555-3745
11	BSBEV	B's Beverages	Victoria Ashworth	Sales Representative	Fauntleroy Circus	London	NULL	EC2 5NT	UK	(171) 555-1212	NULL
12	CACTU	Cactus Comidas para llevar	Patricio Simpson	Sales Agent	Cerrito 333	Buenos Aires	NULL	1010	Argentina	(1) 135-5555	(1) 135-4892
13	CENTC	Centro comercial Moctezuma	Francisco Chang	Marketing Manager	Sierras de Granada 9993	México D.F.	NULL	05022	Mexico	(5) 555-3392	(5) 555-7293
14	CHOPS	Chop-suey Chinese	Yang Wang	Owner	Hauptstr. 29	Bern	NULL	3012	Switzerland	0452-076545	NULL
15	COMMI	Comércio Mineiro	Pedro Afonso	Sales Associate	Av. dos Lusíadas, 23	Sao Paulo	SP	05432-043	Brazil	(11) 555-7647	NULL
16	CONSH	Consolidated Holdings	Elizabeth Brown	Sales Representative	Berkeley Gardens 12 Brewery	London	NULL	WX1 6LT	UK	(171) 555-2282	(171) 555-9199

Şekil 2: Staging tablolarına aktarılan ham verilerin kontrolü.

2.2. Veri Bozulma ve Kalite Testleri

Gerçek dünya veri süreçlerinde, farklı kaynaklardan gelen veriler çoğunlukla eksik, tutarsız veya hatalı alanlar içermektedir. Bu tür kalite problemleri; manuel veri girişi hataları, sistem entegrasyon farklılıkları veya veri aktarım süreçlerindeki aksaklıklardan kaynaklanabilir. Northwind veritabanı temiz ve tutarlı bir yapıya sahip olduğundan, ETL süreçlerinin veri temizleme boyutunu uygulamalı olarak test edebilmek amacıyla staging tablolarına kasıtlı olarak çeşitli veri kalitesi hataları eklenmiştir. Bu yaklaşım, gerçek dünya senaryolarını simüle ederek temizleme stratejilerinin etkinliğini doğrulamayı mümkün kılmaktadır.

2.2.1 Null Değerler

Veri temizleme mantığını test edebilmek amacıyla, staging tablolarında kasıtlı olarak veri kalitesi hataları oluşturulmuştur.

Bu kapsamda, NULL değer problemi simüle edilmiştir. Örnek olarak, ALFKI kodlu müşterinin şehir bilgisi silinerek eksik veri durumu oluşturulmuştur.

```
UPDATE Customers_Staging

SET City = NULL

WHERE CustomerID = 'ALFKI';
```

2.2.2. Tutarsız Veri

Veri setlerinde aynı bilginin farklı formatlarda tutulması, analiz sonuçlarının hatalı olmasına neden olabilir. Bu durumu temsil etmek amacıyla, bazı kayıtların ülke bilgileri standart formattan çıkarılarak küçük harfle ve farklı yazım biçimleriyle değiştirilmiştir.

Örneğin, ANATR kodlu müşterinin ülke bilgisi aşağıdaki sorgu ile 'turkiye' olarak güncellenmiştir:

```
UPDATE Customers_Staging

SET Country = 'turkiye'

WHERE CustomerID = 'ANATR';
```

2.2.3. Boşluk Sorunları

Boşluk sorunlarını temsil etmek amacıyla, bazı kayıtların metin alanlarının başına ve sonuna gereksiz boşluklar eklenmiştir. Bu tür hatalar, özellikle metin karşılaştırmalarında ve filtreleme işlemlerinde yanlış sonuçlara yol açabilmektedir. Örneğin, ANTON kodlu müşterinin şirket adı aşağıdaki sorgu ile güncellenmiştir:

```
UPDATE Customers_Staging

SET CompanyName = '   ABC Company   '

WHERE CustomerID = 'ANTON';
```

2.2.4. Mükerrer (Duplicate) Kayıt Sorunları

Mükerrer kayıt sorunlarını temsil etmek amacıyla, bazı kayıtlar tabloya birden fazla kez eklenmiştir. Bu tür hatalar, veri setinde aynı bilginin tekrar etmesine neden olarak özellikle sayım ve analiz işlemlerinde yanlış sonuçlara yol açabilmektedir. Örneğin, AROUT kodlu müşteri kaydı aşağıdaki sorgu ile tabloya yeniden eklenmiştir:

```
INSERT INTO Customers_Staging

SELECT * FROM Customers_Staging

WHERE CustomerID = 'AROUT';
```

Gerçekleştirilen tüm bu veri bozma işlemleri ve sonuçları Şekil 3'te gösterilmiştir.

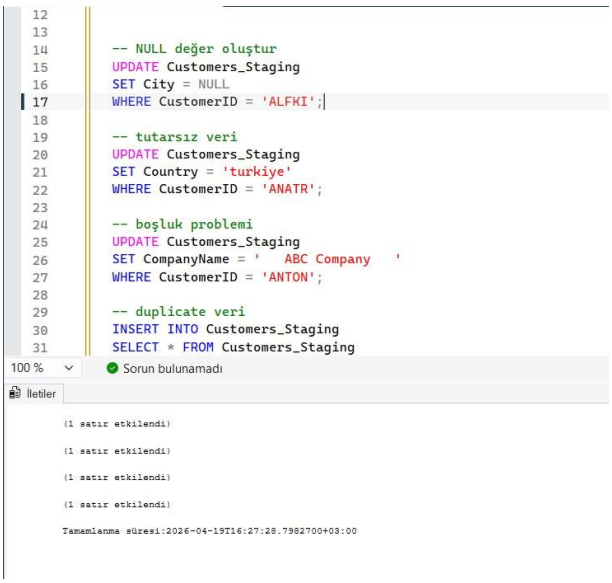

Şekil 3: Test amaçlı veri bozma (NULL, duplicate, hatalı format) işlemleri.

2.3. Veri Temizleme Stratejileri (Transform)

Bu aşamada, staging tabloları üzerinde daha önce oluşturulan veri kalitesi problemlerini gidermeye yönelik temizleme ve standardizasyon işlemleri uygulanmıştır. Amaç, veriyi analiz ve raporlama süreçlerinde güvenilir biçimde kullanılabilecek tutarlı bir yapıya dönüştürmektir. Her bir müdahale, işlem öncesi ve sonrası sorgular ile doğrulanarak veri temizleme sürecinin izlenebilirliği sağlanmıştır.

2.3.1. Null Yönetemi

Veri setlerinde eksik değerler (NULL) analiz süreçlerinde hatalara yol açabileceğinden, bu değerlerin tespit edilmesi ve uygun şekilde doldurulması gerekmektedir.

İlk olarak, şehir bilgisi eksik olan kayıtlar aşağıdaki sorgu ile tespit edilmiş ve çıktısı şekil 4 'te gösterilmiştir:

```
SELECT *

FROM Customers_Staging

WHERE City IS NULL;
```

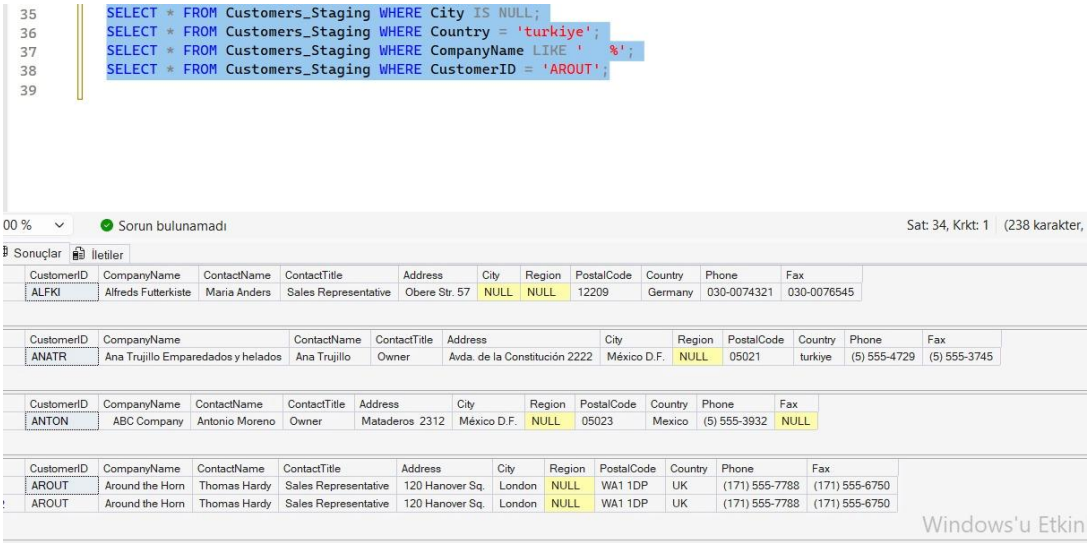

Şekil 4: Veri setindeki eksik ve hatalı kayıtların sorgu ile tespiti.

Tespit edilen NULL değerler, anlamlı bir varsayılan değer olan 'Unknown' ile güncellenmiştir:

```
UPDATE Customers_Staging

SET City = 'Unknown'

WHERE City IS NULL;
```

Şekil 5: Temizleme öncesi NULL şehir bilgisinin durumu.

Son olarak, aynı sorgu tekrar çalıştırılarak NULL değerlerin tamamen giderildiği doğrulanmıştır:

```
SELECT *

FROM Customers_Staging

WHERE City IS NULL;
```

Şekil 6: NULL değerlerin 'Unknown' ile güncellenmesi ve doğrulanması

2.3.2. Mükerrer (Duplicate) Kayıt Kontrolü

Mükerrer kayıtlar, veri setinde aynı bilginin birden fazla kez yer almasına neden olarak analiz sonuçlarını olumsuz etkileyebilir. Bu nedenle, öncelikle tekrar eden kayıtlar tespit edilmiştir:

```
SELECT CustomerID, COUNT(*) as sayi

FROM Customers_Staging

GROUP BY CustomerID

HAVING COUNT(*) > 1;
```

```
SELECT CustomerID, COUNT(*) as sayi
FROM Customers_Staging
GROUP BY CustomerID
HAVING COUNT(*) > 1;
```

00 % Sorun bulunamadı

Sonuçlar | İletiler

CustomerID	sayi
AROUT	2

Şekil 7: Mükerrer (duplicate) kayıtların sayısal tespiti

Tespit edilen mükerrer kayıtlar, ROW_NUMBER() pencere fonksiyonu kullanılarak tekilleştirilmiştir:

```
WITH CTE AS (
SELECT *,
ROW_NUMBER() OVER (PARTITION BY CustomerID ORDER BY CustomerID) as rn
FROM Customers_Staging
)
DELETE FROM CTE WHERE rn > 1;
```

```
WITH CTE AS (
    SELECT *,
    ROW_NUMBER() OVER (PARTITION BY CustomerID ORDER BY CustomerID) as rn
    FROM Customers_Staging
)
DELETE FROM CTE WHERE rn > 1;
```

0 % Sorun bulunamadı

İletiler

```
(1 satır etkilendi)

Tamamlanma süresi:2026-04-19T17:48:55.2244555+03:00
```

Şekil 8: CTE ve ROW_NUMBER() ile mükerrer kayıtların silinmesi

İşlem sonrasında aynı sorgu tekrar çalıştırılarak mükerrer kayıtların tamamen silindiği doğrulanmıştır:

```
SELECT CustomerID, COUNT(*) as sayi
FROM Customers_Staging
GROUP BY CustomerID
HAVING COUNT(*) > 1;
```

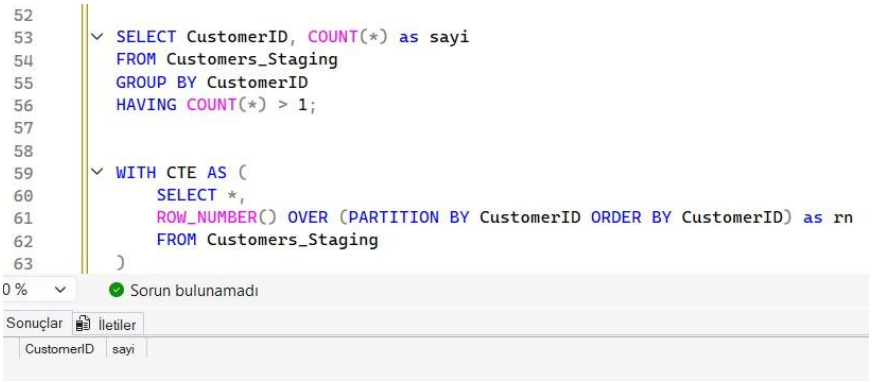

Şekil 9: Silme işlemi sonrası mükerrer kayıt kontrolü

2.3.3. TRIM İşlemi (Boşluk Temizleme)

Metin alanlarında bulunan baş ve son boşluklar, veri karşılaştırma ve filtreleme işlemlerinde hatalara neden olabilir. Bu nedenle, bu tür gereksiz boşluklar temizlenmiştir:

```
UPDATE Customers_Staging

SET CompanyName = LTRIM(RTRIM(CompanyName));
```

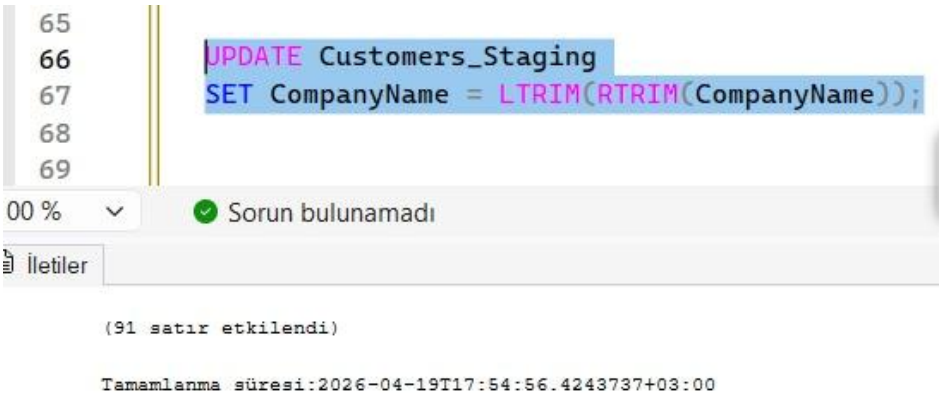

Şekil 10: LTRIM ve RTRIM ile metin başı/sonu boşluklarının temizlenmesi

Temizleme işleminin doğrulanması amacıyla, başında veya sonunda boşluk bulunan kayıtlar tekrar sorgulanmıştır:

```
SELECT CompanyName

FROM Customers_Staging

WHERE CompanyName LIKE ' %' OR CompanyName LIKE '% ';
```

Şekil 11: Boşluk temizleme işleminin başarılı sonuç kümesi

Sorgunun boş sonuç kümesi döndürmesi, işlemin başarıyla tamamlandığını göstermektedir.

2.3.4. Veri Standartlaştırma

Veri standardizasyonu, aynı anlamı taşıyan değerlerin tek bir biçimde temsil edilmesini sağlayarak analiz sonuçlarının doğruluğunu artırır. Özellikle ülke gibi kategorik alanlarda yazım biçimi farklılıkları, gruplama ve raporlama işlemlerinde dağınık sonuçlar üretebileceğinden tüm kayıtlar ortak bir formata dönüştürülmüştür:

```
UPDATE Customers_Staging

SET Country = UPPER(Country);
```

```
74
75
76  UPDATE Customers_Staging
77  SET Country = UPPER(Country);
78
```

Sorun bulunamadı

İletiler

```
(91 satır etkilendi)

Tamamlanma süresi:2026-04-19T17:56:21.3259144+03
```

Şekil 12: Ülke isimlerinin standart büyük harf formatına dönüştürülmesi

İşlem sonrasında tüm kayıtların büyük harf formatına dönüştürüldüğü aşağıdaki sorgu ile kontrol edilmiştir:

```
SELECT DISTINCT Country FROM Customers_Staging;
```

```
79
80
81  SELECT DISTINCT Country FROM Customers_Staging;
```

Sorun bulunamadı

Sonuçlar | İletiler

Country
ARGENTİNA
AUSTRİA
BELGİUM
BRAZİL
CANADA
DENMARK
FİNLAND
FRANCE
GERMANY
IRELAND
ITALY
MEXİCO
NORWAY
POLAND

Şekil 13: Standartlaştırılmış tekil ülke listesi

2.3.5. Mantıksız Veri Kontrolü

Veri setlerinde gerçekçi olmayan (örneğin geleceğe ait) değerler bulunabilir. Bu tür hataları test etmek amacıyla, staging tablosuna kasıtlı olarak hatalı bir tarih değeri eklenmiştir:

```
UPDATE Orders_Staging

SET OrderDate = '2099-01-01'

WHERE OrderID = 10248;
```

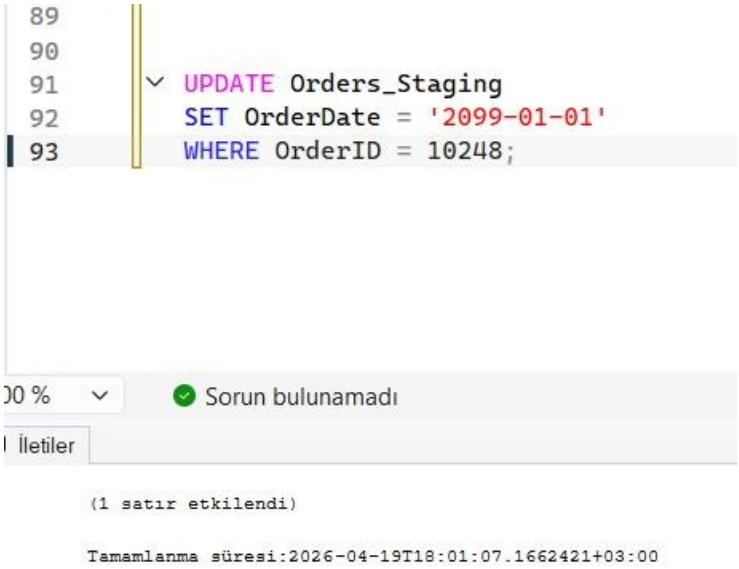

Şekil 14: Test amaçlı mantıksız (gelecek tarihli) veri eklenmesi

Ardından, geleceğe ait tarih içeren kayıtlar aşağıdaki sorgu ile tespit edilmiştir:

```
SELECT *

FROM Orders_Staging

WHERE OrderDate > GETDATE();
```

```
SELECT *
FROM Orders_Staging
WHERE OrderDate > GETDATE();
```

Sorun bulunamadı Sat: 94, Krkt: 1 (63 karakter, 5 çizgi) BŞL CRLF UTF-

Sonuçlar İletiler

OrderID	CustomerID	EmployeeID	OrderDate	RequiredDate	ShippedDate	ShipVia	Freight	ShipName	ShipAddress	ShipCity	ShipRegion	ShipPostalCode	ShipCountry
10248	VINET	5	2099-01-01 00:00:00.000	1996-08-01 00:00:00.000	1996-07-16 00:00:00.000	3	32,38	Vins et alcools Chevalier	59 rue de l'Abbaye	Reims	NULL	51100	France

Şekil 15: Hatalı tarih içeren kayıtların sistem zamanına göre tespiti

Tespit edilen mantıksız tarih değerleri, sistemin güncel tarihi ile düzeltilmiştir.
Bu senaryoda temel amaç, mantıksız veri tespiti ve düzeltme mekanizmasını test etmek olduğundan, hatalı tarih değeri GETDATE() fonksiyonu ile güncel tarihe çekilmiştir. Gerçek dünya uygulamalarında ise bu tür kayıtlar için tercih edilecek yaklaşım, verinin kaynağına ve iş kurallarına göre farklılık gösterebilir; değerin NULL olarak işaretlenmesi ya da kaydın tamamen dışarıda bırakılması da yaygın alternatifler arasında yer almaktadır.

```
UPDATE Orders_Staging

SET OrderDate = GETDATE()

WHERE OrderDate > GETDATE();
```

```
UPDATE Orders_Staging
SET OrderDate = GETDATE()
WHERE OrderDate > GETDATE();
```

100 % Sorun bulunamadı

İletiler

```
(1 satır etkilendi)

Tamamlanma süresi:2026-04-19T18:02:36.5440773+03:00
```

Şekil 16: Mantıksız tarihlerin güncel sistem tarihiyle düzeltilmesi

Son olarak, aynı sorgu tekrar çalıştırılarak hatalı verilerin tamamen giderildiği doğrulanmıştır:

```
SELECT *

FROM Orders_Staging

WHERE OrderDate > GETDATE();
```

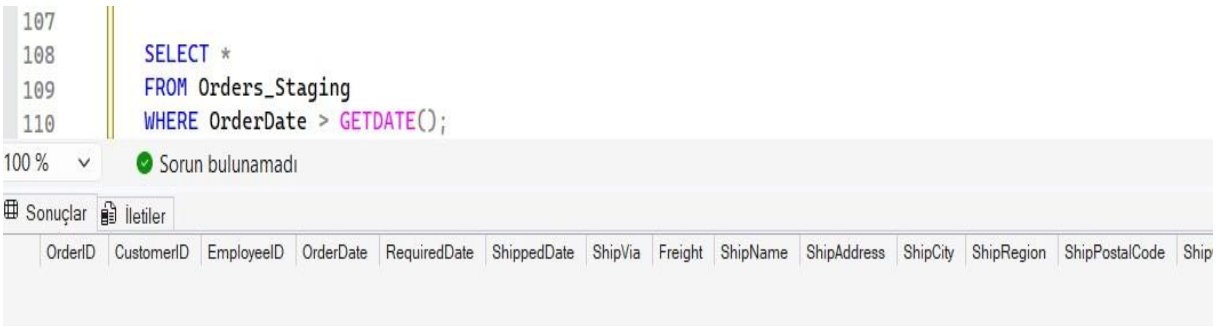

Şekil 17: Tarih düzeltme sonrası veri tutarlılık kontrolü

2.4. Veri Dönüştürme ve Zenginleştirme

Veri temizleme işlemlerinin tamamlanmasının ardından, elde edilen verilerin analiz süreçlerinde daha anlamlı ve kullanışlı hale getirilmesi amacıyla dönüştürme (transform) ve zenginleştirme işlemleri uygulanmıştır.

2.4.1. Yeni Alan Oluşturma (OrderYear)

Yıl bazlı analizleri kolaylaştırmak amacıyla, sipariş tarihinden yıl bilgisi türetilerek tabloya yeni bir sütun eklenmiştir. Bu sayede zaman bazlı analizlerin performansı artırılmıştır.

```
ALTER TABLE Orders_Staging ADD OrderYear INT;

UPDATE Orders_Staging

SET OrderYear = YEAR(OrderDate);
```

```
ALTER TABLE Orders_Staging
ADD OrderYear INT;

UPDATE Orders_Staging
SET OrderYear = YEAR(OrderDate);
```

100 % 1 0

İletiler

(830 satır etkilendi)

Tamamlanma süresi:2026-04-19T19:41:23.6317808+03:00

Şekil 18: Tabloya türetilmiş 'OrderYear' sütununun eklenmesi

Eklenen sütunun doğruluğunu kontrol etmek amacıyla aşağıdaki sorgu çalıştırılmıştır:

```
SELECT OrderDate, OrderYear

FROM Orders_Staging;
```

```
SELECT OrderDate, OrderYear
FROM Orders_Staging;
```

00 % 2 0

Sonuçlar İletiler

OrderDate	OrderYear
2026-04-19 18:02:36.540	2026
1996-07-05 00:00:00.000	1996
1996-07-08 00:00:00.000	1996
1996-07-08 00:00:00.000	1996
1996-07-09 00:00:00.000	1996
1996-07-10 00:00:00.000	1996
1996-07-11 00:00:00.000	1996
1996-07-12 00:00:00.000	1996
1996-07-15 00:00:00.000	1996
1996-07-16 00:00:00.000	1996
1996-07-17 00:00:00.000	1996
1996-07-18 00:00:00.000	1996
1996-07-19 00:00:00.000	1996
1996-07-19 00:00:00.000	1996

Şekil 19: Sipariş tarihinden yıl bilgisinin çıkarılarak kontrol edilmesi

2.4.2. Veri Kategorizasyonu (FreightCategory)

Sayısal veri tipinde olan kargo ücretleri (Freight), daha kolay analiz edilebilmesi amacıyla kategorilere ayrılmıştır. Bu işlem ile veriler yorumlanabilir hale getirilmiş ve analitik sorgular için uygun bir yapı oluşturulmuştur.

```
SELECT OrderID, Freight,
       CASE
           WHEN Freight < 50 THEN 'LOW'
           WHEN Freight BETWEEN 50 AND 100 THEN 'MEDIUM'
           ELSE 'HIGH'
       END as FreightCategory
FROM Orders_Staging;
```

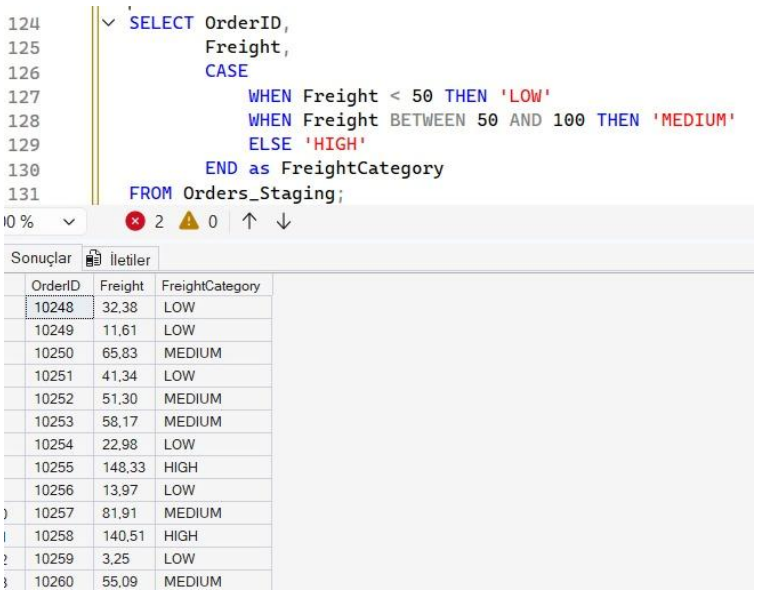

```
SELECT OrderID,
       Freight,
       CASE
           WHEN Freight < 50 THEN 'LOW'
           WHEN Freight BETWEEN 50 AND 100 THEN 'MEDIUM'
           ELSE 'HIGH'
       END as FreightCategory
FROM Orders_Staging;
```

Sonuçlar | İletiler

OrderID	Freight	FreightCategory
10248	32,38	LOW
10249	11,61	LOW
10250	65,83	MEDIUM
10251	41,34	LOW
10252	51,30	MEDIUM
10253	58,17	MEDIUM
10254	22,98	LOW
10255	148,33	HIGH
10256	13,97	LOW
10257	81,91	MEDIUM
10258	140,51	HIGH
10259	3,25	LOW
10260	55,09	MEDIUM

Şekil 20: Kargo ücretlerinin analitik kategorilere ayrılması

2.4.3. Veri Zenginleştirme (JOIN)

Farklı tablolar arasında ilişki kurularak veri zenginleştirme işlemi gerçekleştirilmiştir. Bu kapsamda, sipariş verileri ile müşteri verileri birleştirilmiş ve her siparişin hangi müşteri tarafından verildiği bilgisi tek bir görünümde toplanmıştır.

```
SELECT o.OrderID, c.CompanyName, o.OrderDate
FROM Orders_Staging o
JOIN Customers_Staging c
ON o.CustomerID = c.CustomerID;
```

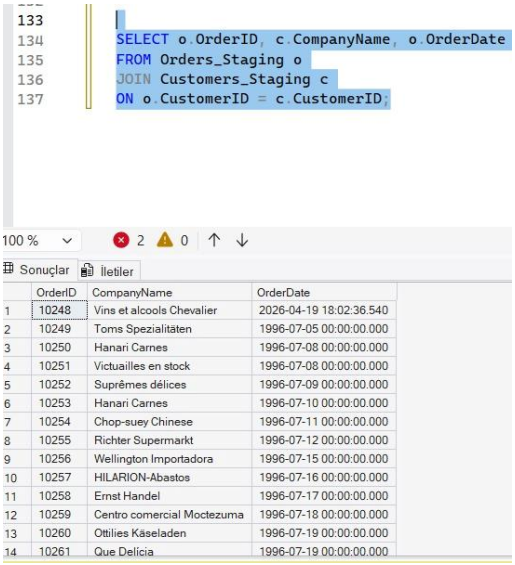

Şekil 21: JOIN işlemiyle müşteri ve sipariş verilerinin zenginleştirilmesi

2.5. Veri Yükleme (Load)

ETL sürecinin son aşamasında, temizlenen ve dönüştürülen veriler analiz süreçlerinde kullanılmak üzere nihai tabloya aktarılmıştır.

2.5.1. Nihai Tabloların Oluşturulması

Transform aşamasında uygulanan tüm temizleme, dönüştürme ve zenginleştirme işlemleri tek bir sorgu altında birleştirilerek Clean_Orders adlı yeni bir tablo oluşturulmuştur. Bu tablo, analiz için hazır ve tutarlı bir veri yapısı sunmaktadır.

```
SELECT
    o.OrderID,
    c.CompanyName,
    c.Country,
    o.OrderDate,
    YEAR(o.OrderDate) as OrderYear,
    o.Freight,
    CASE
        WHEN o.Freight < 50 THEN 'LOW'
        WHEN o.Freight BETWEEN 50 AND 100 THEN 'MEDIUM'
        ELSE 'HIGH'
    END as FreightCategory
```

```
INTO Clean_Orders
FROM Orders_Staging o
JOIN Customers_Staging c
ON o.CustomerID = c.CustomerID;
```

```
141    SELECT
142        o.OrderID,
143        c.CompanyName,
144        c.Country,
145        o.OrderDate,
146        YEAR(o.OrderDate) as OrderYe
147        o.Freight
148    INTO Clean_Orders
149    FROM Orders_Staging o
150    JOIN Customers_Staging c
151    ON o.CustomerID = c.CustomerID;
```

```
) %    2  0
İletiler

(830 satır etkilendi)

Tamamlanma süresi:2026-04-19T19:57:26.2205637+03:00
```

Şekil 22: İşlenmiş verilerin nihai 'Clean_Orders' tablosuna yüklenmesi

Oluşturulan Clean_Orders tablosu, veritabanı içerisindeki tablo listesi üzerinden de kontrol edilmiştir.

Şekil 23: Nihai tablonun veritabanı şemasındaki konumu

2.5.2. Nihai Veri Kontrolü

Yükleme işleminin ardından, oluşturulan tablonun içeriği aşağıdaki sorgu ile görüntülenerek verilerin doğru şekilde aktarıldığı doğrulanmıştır:

```
SELECT * FROM Clean_Orders;
```

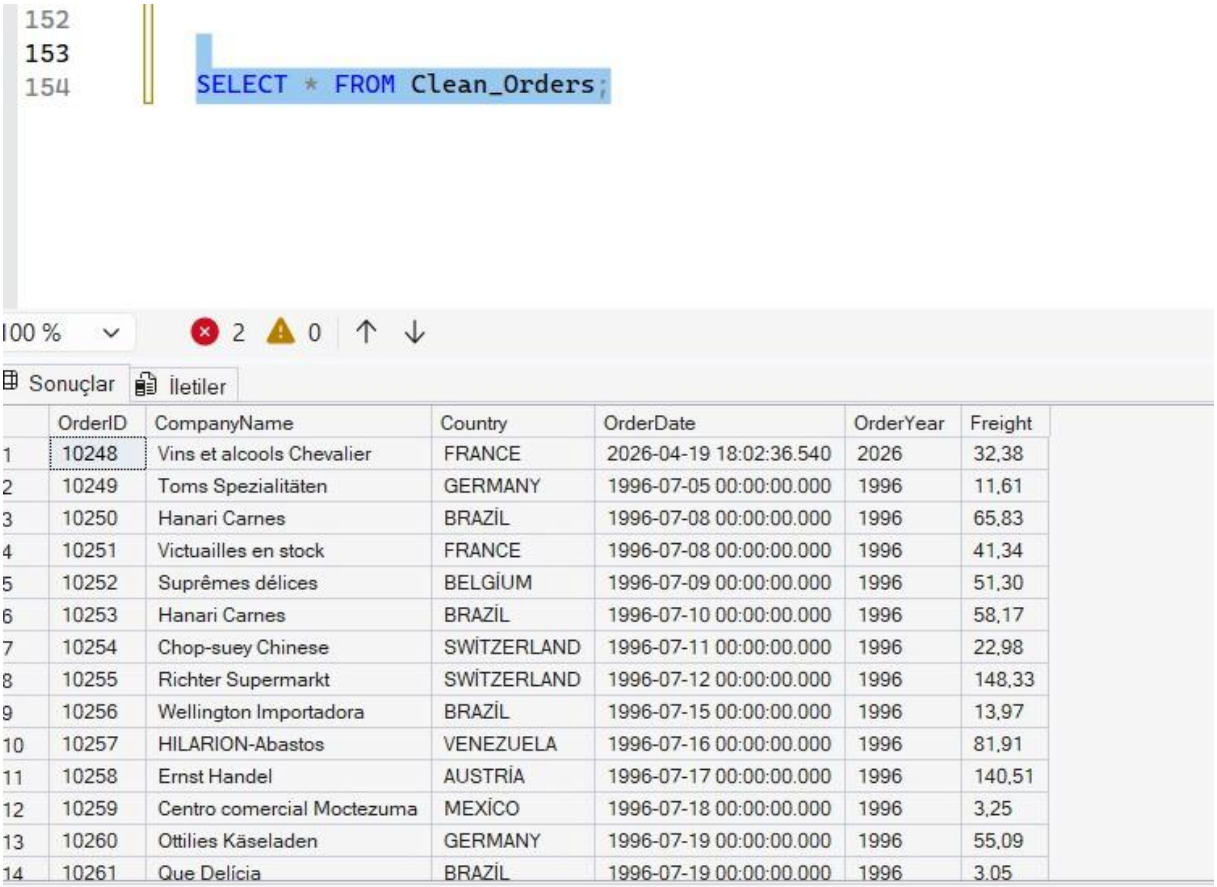

	OrderID	CompanyName	Country	OrderDate	OrderYear	Freight
1	10248	Vins et alcools Chevalier	FRANCE	2026-04-19 18:02:36.540	2026	32,38
2	10249	Toms Spezialitäten	GERMANY	1996-07-05 00:00:00.000	1996	11,61
3	10250	Hanari Carnes	BRAZİL	1996-07-08 00:00:00.000	1996	65,83
4	10251	Victuailles en stock	FRANCE	1996-07-08 00:00:00.000	1996	41,34
5	10252	Suprêmes délices	BELGİUM	1996-07-09 00:00:00.000	1996	51,30
6	10253	Hanari Carnes	BRAZİL	1996-07-10 00:00:00.000	1996	58,17
7	10254	Chop-suey Chinese	SWİTZERLAND	1996-07-11 00:00:00.000	1996	22,98
8	10255	Richter Supermarkt	SWİTZERLAND	1996-07-12 00:00:00.000	1996	148,33
9	10256	Wellington Importadora	BRAZİL	1996-07-15 00:00:00.000	1996	13,97
10	10257	HILARION-Abastos	VENEZUELA	1996-07-16 00:00:00.000	1996	81,91
11	10258	Ernst Handel	AUSTRİA	1996-07-17 00:00:00.000	1996	140,51
12	10259	Centro comercial Moctezuma	MEXİCO	1996-07-18 00:00:00.000	1996	3,25
13	10260	Ottilies Käseladen	GERMANY	1996-07-19 00:00:00.000	1996	55,09
14	10261	Que Delícia	BRAZİL	1996-07-19 00:00:00.000	1996	3,05

Şekil 24: Analiz ve raporlamaya hazır nihai veri seti çıktısı

2.6. Veri Kalitesi Kontrolü ve Raporlama

ETL sürecinin tamamlanmasının ardından, gerçekleştirilen veri temizleme ve dönüştürme işlemlerinin doğruluğunu ve etkinliğini değerlendirmek amacıyla çeşitli kalite kontrol ve raporlama sorguları çalıştırılmıştır.

2.6.1. Eksik Veri ve Düzeltme İstatistikleri

Transform aşamasında NULL olan şehir bilgileri 'Unknown' değeri ile güncellenmiştir. Bu işlemin doğruluğunu sayısal olarak teyit etmek amacıyla aşağıdaki sorgu çalıştırılmıştır:

```
SELECT COUNT(*) as EksikSehir

FROM Customers_Staging

WHERE City = 'Unknown';
```

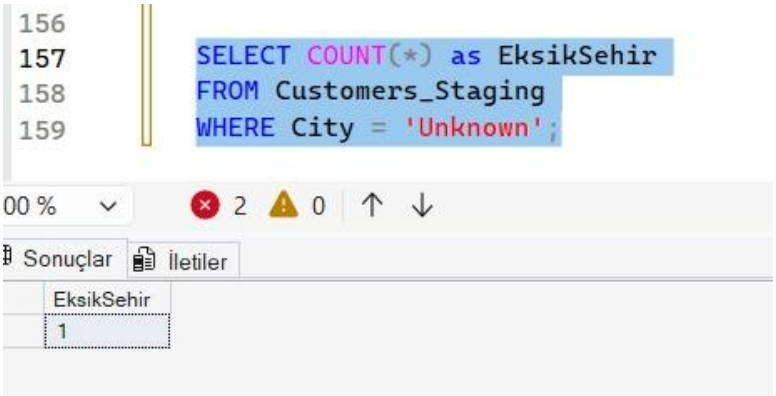

Şekil 25: NULL değer düzeltme işleminin istatistiksel teyidi

Sorgu sonucunun 1 olarak dönmesi, veri setine kasıtlı olarak eklenen eksik şehir bilgisinin başarıyla doldurulduğunu göstermektedir.

2.6.2. Mükerrer Kayıt Sonrası Tablo Durumu

Mükerrer kayıtların temizlenmesinin ardından, tablodaki toplam kayıt sayısı kontrol edilmiştir:

```
SELECT COUNT(*)

FROM Customers_Staging;
```

```
160
161
162
163   SELECT COUNT(*) FROM Customers_Staging;
```

100 % 2 0

Sonuçlar | İletiler

	(Sütun adı yok)
1	91

Şekil 26: İşlem sonrası toplam kayıt sayısının orijinal veriyle doğrulanması

Sorgu sonucunun 91 olarak dönmesi, Northwind veritabanındaki orijinal Customers tablosu ile birebir örtüşmektedir. Bu durum, simüle edilen mükerrer kaydın başarıyla silindiğini ve veri setinin özgün haline döndüğünü göstermektedir.

2.6.3. Ülke Dağılımı ve Standartlaştırma Analizi

Veri standartlaştırma işleminin doğruluğunu kontrol etmek amacıyla, ülke bazlı müşteri dağılımı analiz edilmiştir:

```
SELECT Country, COUNT(*) as sayi

FROM Customers_Staging

GROUP BY Country;
```

```
164
165
166   SELECT Country, COUNT(*)
167   FROM Customers_Staging
168   GROUP BY Country;
```

100 % 2 0

Sonuçlar | İletiler

	Country	(Sütun adı yok)
1	ARGENTİNA	3
2	AUSTRİA	2
3	BELGİUM	2
4	BRAZİL	9
5	CANADA	3
6	DENMARK	2
7	FİNLAND	2
8	FRANCE	11
9	GERMANY	11
10	IRELAND	1
11	ITALY	3
12	MEXİCO	4
13	NORWAY	1
14	POLAND	1

Şekil 27: Standartlaştırılmış veriler üzerinden ülke bazlı dağılım analizi

Elde edilen sonuçlarda tüm ülke isimlerinin büyük harf formatında olduğu gözlemlenmiştir. Özellikle küçük harfli olarak girilen 'turkiye' değerinin 'TURKEY'

formatına dönüştürüldüğü doğrulanmıştır. Bu durum, veri standardizasyonunun başarıyla uygulandığını göstermektedir.

2.6.4. Kargo Ücretleri (Freight) Dağılım Analizi

Transform aşamasında oluşturulan kategori mantığı kullanılarak, siparişlerin kargo maliyetlerine göre dağılımı analiz edilmiştir:

```
SELECT
    CASE
        WHEN Freight < 50 THEN 'LOW'
        WHEN Freight BETWEEN 50 AND 100 THEN 'MEDIUM'
        ELSE 'HIGH'
    END as kategori,
    COUNT(*) as sayi
FROM Orders_Staging
GROUP BY
    CASE
        WHEN Freight < 50 THEN 'LOW'
        WHEN Freight BETWEEN 50 AND 100 THEN 'MEDIUM'
        ELSE 'HIGH'
    END;
```

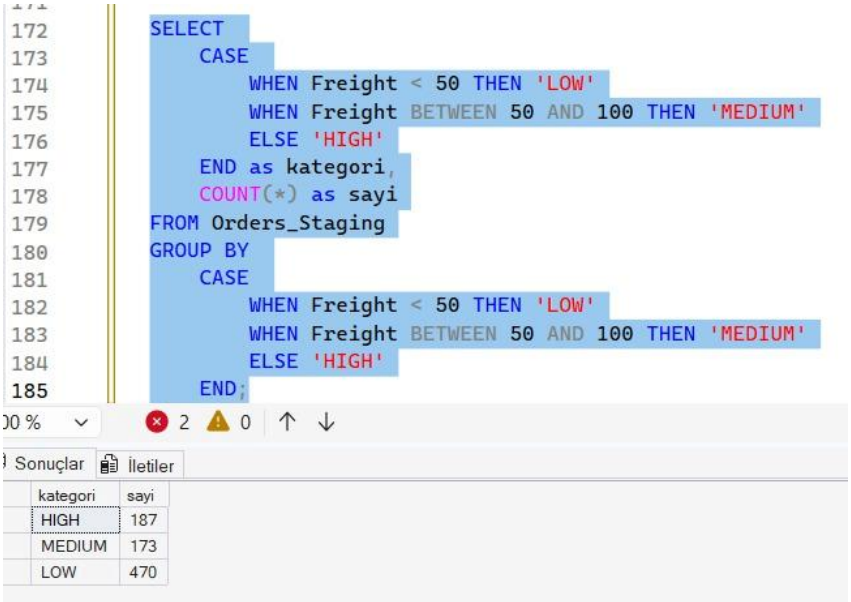

Şekil 28: Kargo maliyet kategorilerine göre sipariş dağılım raporu

Elde edilen sonuçlara göre toplam 830 sipariş kaydının 470'i (%57) düşük, 173'ü (%21) orta ve 187'si (%22) yüksek kargo maliyeti kategorisinde yer almaktadır. Bu dağılım, veri setinin analiz için uygun hale getirildiğini ve anlamlı içgörüler üretilebileceğini göstermektedir.

3. SONUÇ

Bu çalışmada Northwind veritabanı üzerinde uçtan uca bir ETL (Extract, Transform, Load) süreci tasarlanmış ve uygulanmıştır. Gerçek dünya veri kalitesi problemleri simüle edilerek sistematik temizleme ve dönüştürme adımları hayata geçirilmiştir.

Extract aşamasında, ham veriler orijinal tablolara müdahale edilmeden staging alanına aktarılmıştır. Bu yaklaşım, veri bütünlüğünü koruma ve olası hatalar durumunda geri dönüş imkânı sağlama açısından veri mühendisliği süreçlerinde kritik bir öneme sahiptir.

Transform aşamasında, veri kalitesini etkileyen beş temel problem ele alınmıştır. NULL değerler anlamlı bir varsayılan değer ile doldurulmuş, mükerrer kayıtlar ROW_NUMBER() pencere fonksiyonu kullanılarak tekilleştirilmiş, metin alanlarındaki gereksiz boşluklar LTRIM ve RTRIM fonksiyonları ile temizlenmiş, ülke isimleri UPPER() fonksiyonu ile standart bir formata dönüştürülmüş ve mantıksız sipariş kayıtları düzeltilmiştir. Tüm bu işlemler, uygulama öncesi ve sonrası çalıştırılan doğrulama sorguları ile kontrol edilmiştir. Ayrıca veri seti, OrderYear türetilmiş sütunu ve FreightCategory kategorizasyonu ile analitik açıdan zenginleştirilmiştir.

Load aşamasında ise gerçekleştirilen tüm dönüşümler tek bir sorgu altında birleştirilerek Clean_Orders adlı nihai tablo oluşturulmuştur. Bu tablo; sipariş kimliği, şirket adı, ülke, sipariş tarihi, sipariş yılı, kargo ücreti ve kargo kategorisi gibi alanları bir arada sunarak analiz süreçleri için hazır bir veri yapısı sağlamaktadır.

Gerçekleştirilen kalite kontrol ve raporlama işlemleri sonucunda elde edilen bulgular aşağıda özetlenmiştir:

- 1 adet NULL şehir verisi başarıyla doldurulmuştur
- 1 adet mükerrer kayıt silinmiştir
- Tüm 91 müşteri kaydı standart büyük harf formatına dönüştürülmüştür
- 1 adet mantıksız tarih verisi düzeltilmiştir

Sipariş verileri incelendiğinde toplam 830 kaydın 470'inin (%57) düşük, 173'ünün (%21) orta ve 187'sinin (%22) yüksek kargo maliyeti kategorisinde yer aldığı görülmüştür. Bu dağılım, veri setinin analiz için uygun hale getirildiğini ve anlamlı içgörüler üretilebileceğini göstermektedir.

Bu süreç, veri kalitesinin analitik sistemlerdeki belirleyici rolünü uygulamalı olarak ortaya koymuştur.